UANL
UNIVERSIDAD AUTÓNOMA DE NUEVO LEÓN

FCFM
FACULTAD DE CIENCIAS FÍSICO MATEMÁTICAS

UNIVERSIDAD AUTÓNOMA DE NUEVO LEÓN

FACULTAD DE CIENCIAS FÍSICO MATEMÁTICAS

Algoritmia y Optimización

Reporte Tarea 3 – Opción A

Estudiante: Sthefany Paola Díaz Pérez

Matrícula: 2163269

Grupo: 032

Repositorio: https://github.com/sthefanydiaz07/Algoritmia-y-Optimizacion-Tarea3

La temperatura inicial T_0 no cambia de forma significativa el costo del recocido simulado por sí sola (p = 0.418), pero su efecto depende del tamaño del problema (interacción, p = 0.035). La mejor T_0 es 48.89 para n = 10 y 19.19 para n = 15; para n = 5 no hay diferencia entre temperaturas.

1. Diseño experimental

Se ajustó la temperatura inicial T_0 del recocido simulado con 2-opt (Tarea 2, Ejercicio 4) con un diseño factorial completo 3 × 3 (Opción A): 3 niveles de temperatura × 3 tamaños de problema × 10 réplicas = 90 corridas.

- **Factor:** temperatura inicial T_0, con tres niveles (bajo, medio, alto).
- **Bloque:** tamaño del TSP, n = 5, 10 y 15 ciudades, con una sola instancia fija por tamaño (coordenadas enteras entre 0 y 100, generadas con semilla fija).
- **Réplicas:** 10 por cada combinación temperatura × tamaño. Cada corrida usa una semilla distinta y un recorrido inicial aleatorio distinto, para capturar la aleatoriedad del algoritmo.
- **Respuesta:** longitud del recorrido final (costo).

Niveles de temperatura. Se fijó la semilla con la matrícula (`random.seed(2163269)`) y se generó un solo número aleatorio, r = 0.6125, que se usó en todo el experimento. Se definió el rango [$T_{mín}$, $T_{máx}$] = [1, 100]. Las diferencias de costo entre recorridos vecinos son de decenas de unidades (coordenadas entre 0 y 100), así que $T_{mín}$ = 1 corresponde a un recocido casi codicioso, que acepta casi solo mejoras, y $T_{máx}$ = 100 a uno muy exploratorio; además $T_{mín}$ es mayor que T_{final} = 0.01. Cada fracción se convirtió con T = $T_{mín}$ + fracción · ($T_{máx}$ − $T_{mín}$).

Nivel	Fracción	T_0
Bajo	0.3r = 0.1838	19.19
Medio	0.3r + 0.3 = 0.4838	48.89
Alto	0.3r + 0.6 = 0.7838	78.59

Parámetros fijos. Solo cambia T_0; todo lo demás se mantuvo igual en las 90 corridas: movimiento 2-opt, N = 3000 iteraciones, T_{final} = 0.01 y enfriamiento exponencial,

$$T(t) = T_0 \left(\frac{T_{final}}{T_0}\right)^{\frac{t}{N}}$$

Se eligió el esquema exponencial porque en la Tarea 2 dio mejor calidad con presupuestos pequeños (razón media 1.059 contra 1.202 del lineal con 100 iteraciones, y 1.018 contra 1.072 con 300), y porque fue el que se usó en el Ejercicio 5.

2. ANOVA de dos factores

El tamaño del problema explica casi toda la variación del costo ($p \approx 1 \times 10^{-117}$), la temperatura no es significativa por sí sola ($p = 0.418$) y la interacción temperatura × tamaño sí lo es ($p = 0.035$). Se usó `ols('costo ~ C(temperatura) * C(tamano)')` y `anova_lm(modelo, typ=2)` con $\alpha = 0.05$.

Fuente	Suma de cuadrados	gl	F	p-value	Significativo ($\alpha = 0.05$)
Temperatura	12.04	2	0.881	0.418	No
Tamaño	426,289.58	2	31,206.39	1.15×10^{-117}	Sí
Temperatura × tamaño	74.31	4	2.720	0.0352	Sí
Residual (error)	553.24	81			

Hipótesis. Para cada efecto, H_0 dice que no tiene efecto sobre el costo y H_1 dice que sí lo tiene. Con $\alpha = 0.05$: si $p < 0.05$, H_0 se rechaza. Entonces existe suficiente evidencia estadística para rechazar H_0. Si $p \geq 0.05$, H_0 no se rechaza. Entonces no existe suficiente evidencia estadística para rechazar H_0.

- **Temperatura ($p = 0.418$).** H_0 no se rechaza. Entonces no existe suficiente evidencia estadística para rechazar H_0. En conclusión, la temperatura inicial T_0 no afecta de forma significativa el costo por sí sola.
- **Tamaño ($p = 1.15 \times 10^{-117}$).** H_0 se rechaza. Entonces existe suficiente evidencia estadística para rechazar H_0. En conclusión, el tamaño del problema afecta de forma significativa el costo.
- **Interacción ($p = 0.0352$).** H_0 se rechaza. Entonces existe suficiente evidencia estadística para rechazar H_0. En conclusión, el efecto de la temperatura sobre el costo depende del tamaño del problema.

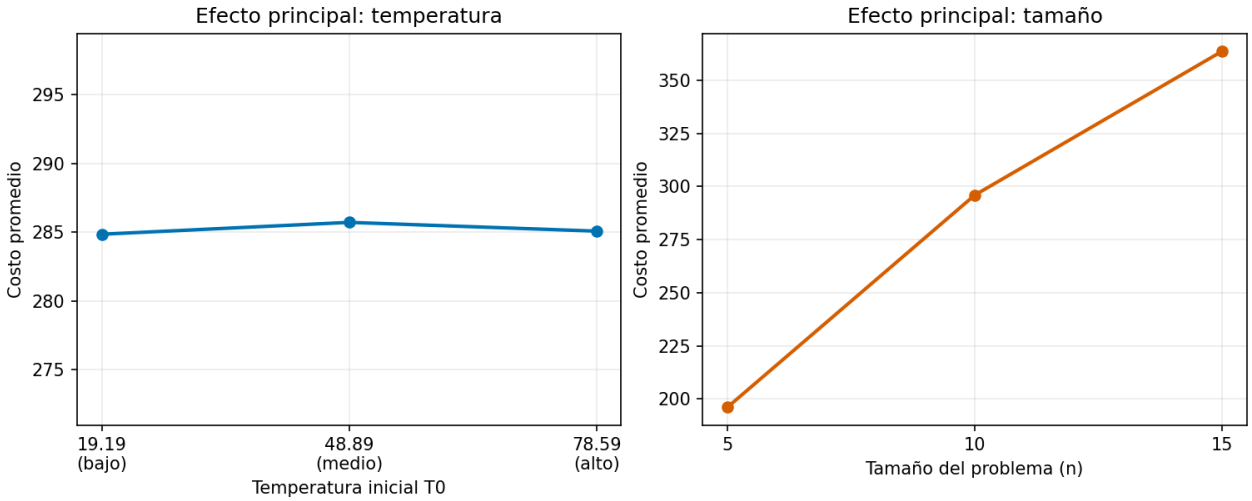


Figura 1. Efectos principales de la temperatura y del tamaño sobre el costo promedio. El eje de la temperatura abarca ±5% alrededor de la media, así que las diferencias entre niveles (menos de 1 unidad de costo) se ven casi planas.

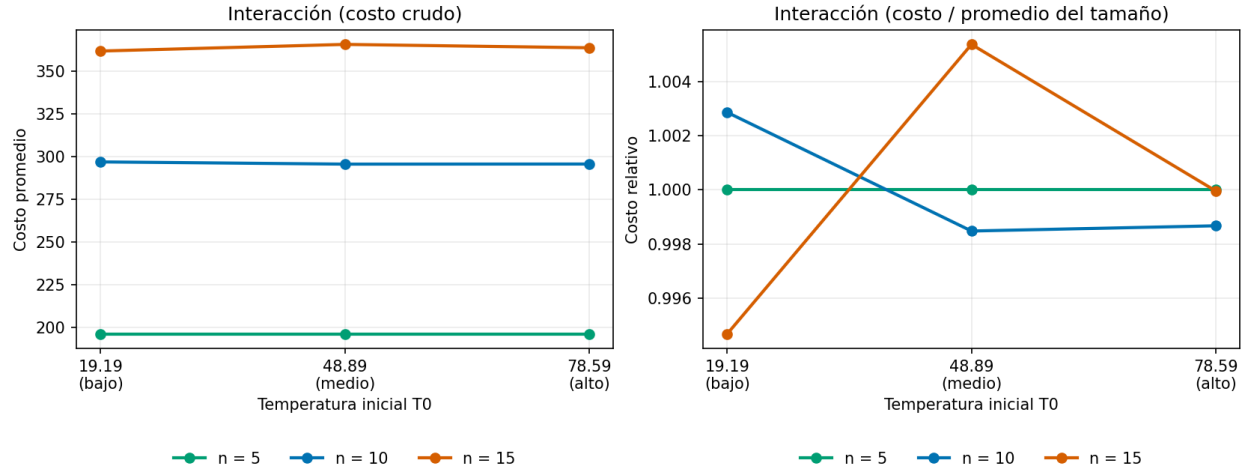


Figura 2. Interacción temperatura × tamaño. Izquierda: costo promedio. Derecha: costo dividido entre el promedio de cada tamaño, para comparar las tres curvas en la misma escala.

Cómo se lee.

- **Tamaño:** el costo promedio sube de 196.07 (n = 5) a 295.93 (n = 10) y 363.63 (n = 15). Es lo esperado: más ciudades implican recorridos más largos.
- **Temperatura:** los promedios por nivel (284.85, 285.71 y 285.07 para T_0 = 19.19, 48.89 y 78.59) son casi iguales, y por eso el efecto principal no es significativo.
- **Interacción:** las líneas de la Figura 2 no son paralelas, es decir, el mejor nivel de temperatura depende de n. En n = 15 la temperatura baja da el menor costo promedio (361.69 contra 365.58 y 363.61). En n = 10 la temperatura baja es la peor (296.77 contra 295.47 y 295.53). En n = 5 las tres líneas coinciden. El efecto es pequeño, de alrededor de 1% del costo (panel derecho de la Figura 2), y su p-value está cerca del límite de 0.05.

3. Bootstrap de la mediana

Como la interacción temperatura × tamaño resultó significativa, se calculó la mediana bootstrap y su IC 95% en los 9 puntos de diseño. En 5 de los 9 el intervalo tiene ancho cero porque casi todas las réplicas dieron el mismo costo.

Método. Para cada punto se remuestrearon con reemplazo sus 10 costos, 10000 veces. Se calculó la mediana de cada remuestreo; el valor reportado es la mediana de esas medianas, y el IC 95% son los percentiles 2.5 y 97.5.

Tamaño (n)	T_0	Mediana bootstrap	IC 95%	Media muestral
5	19.19	196.07	[196.07, 196.07]	196.07
5	48.89	196.07	[196.07, 196.07]	196.07
5	78.59	196.07	[196.07, 196.07]	196.07
10	19.19	295.47	[295.47, 298.74]	296.77
10	48.89	295.47	[295.47, 295.47]	295.47
10	78.59	295.47	[295.47, 295.62]	295.53
15	19.19	360.73	[360.73, 360.73]	361.69
15	48.89	365.53	[360.73, 370.45]	365.58
15	78.59	360.73	[360.73, 370.33]	363.61

Cómo se lee. Los costos son discretos: el recocido termina casi siempre en la misma mejor ruta y, a veces, en una ligeramente peor. Por eso las medianas coinciden en varios puntos y los intervalos son tan estrechos. Por ejemplo, con n = 15 y T_0 = 19.19, 9 de las 10 réplicas dieron 360.73; con T_0 = 48.89 solo 5 de 10 (el resto cayó en rutas cercanas a 370), y de ahí el IC superior de 370.45. En n = 5 las 30 corridas dieron exactamente 196.07, así que no hay variabilidad que medir.

4. Temperatura óptima por tamaño

La mejor T_0 es 48.89 para n = 10 y 19.19 para n = 15; en n = 5 las tres temperaturas empatan. El criterio fue la menor mediana bootstrap; si dos temperaturas empatan, la menor media muestral, y después el menor IC superior.

Tamaño (n)	T_0 óptima	Mediana bootstrap	IC 95%	Cómo se llegó a esa conclusión
5	Cualquiera (empate técnico; 19.19 por convención)	196.07	[196.07, 196.07]	Las 30 corridas dan el mismo costo; el ANOVA no puede distinguir temperaturas.

Tamaño (n)	T_0 óptima	Mediana bootstrap	IC 95%	Cómo se llegó a esa conclusión
10	48.89	295.47	[295.47, 295.47]	Las tres medianas empatan en 295.47. Gana por menor media (295.47 contra 295.53 y 296.77) y por el IC más estrecho.
15	19.19	360.73	[360.73, 360.73]	Empata en mediana con T_0 = 78.59 (360.73) y supera a T_0 = 48.89 (365.53). Gana por menor media (361.69 contra 363.61 y 365.58) y por el IC más estrecho.

Las diferencias son pequeñas: entre la mejor y la peor temperatura hay menos de 5 unidades de costo (0.4% en n = 10 y 1.1% en n = 15).

5. Análisis final

La temperatura que gana sí cambia con n, pero no hay una tendencia clara entre n y T_0*: las diferencias son de 1% del costo o menos y la evidencia estadística está cerca del límite.

¿La temperatura óptima cambia con el tamaño del problema? La temperatura con mejor desempeño observado cambia (48.89 en n = 10 y 19.19 en n = 15), y la interacción significativa (p = 0.035) confirma que el efecto de T_0 depende de n. En conclusión, el cambio del óptimo es pequeño y no se puede afirmar que sea real.

¿Hay una tendencia clara entre n y T*? No. Con tres tamaños y un n = 5 sin óptimo no se puede hablar de una tendencia. De n = 10 a n = 15 la mejor temperatura baja de 48.89 a 19.19, pero la diferencia es pequeña (menos de 5 unidades de costo) y el p-value de la interacción es cercano a 0.05, así que no es suficiente para afirmar que T_0* disminuye al crecer n; podría deberse al azar de las 10 réplicas.

Por qué la temperatura pesa tan poco. Con 3000 iteraciones y enfriamiento exponencial, el recocido casi siempre encuentra la mejor ruta sin importar T_0. Es coherente con la Tarea 2, donde con 3000 iteraciones el esquema exponencial encontró el óptimo en 30 de 30 corridas (n = 10, T_0 = 100). Los tres niveles probados (19.19, 48.89 y 78.59) llegan casi siempre al mismo resultado.

Limitaciones.

- Los costos son discretos y repetidos (y en n = 5 la varianza es cero), así que no se cumplen del todo los supuestos de normalidad y varianzas iguales del ANOVA; sus p-values son aproximados.
- Hay una sola instancia por tamaño y solo 10 réplicas por punto: con otra instancia u otras semillas el orden de las temperaturas podría cambiar.
- El tamaño domina la variación total, por lo que las comparaciones de temperatura tienen sentido solo dentro de cada n.
- Solo se probaron tres temperaturas y tres tamaños.

Conclusión. Con este presupuesto, cualquier T_0 entre 19 y 79 da resultados casi equivalentes. Si hay que elegir, la mejor opción observada es T_0 = 48.89 para n = 10 y T_0 = 19.19 para n = 15. Para medir el efecto con más sensibilidad habría que usar instancias más grandes, otro presupuesto de iteraciones o más réplicas.